Mateusz Daszewski i Miłosz Andryszczuk

LAB5

Wstęp

Implementacja algorytmu znajduje się w pliku MLP, generowanie wykresów w pliku graphs.

Użyte biblioteki/funkcje:

- sklearn
- numpy
- ProcessPoolExecutor z concurrent.futures
- Pyplot

W implementacji grafów została użyte ProcessPoolExecutror w celu znaczącego przyśpieszenia wykonywania się wykresów

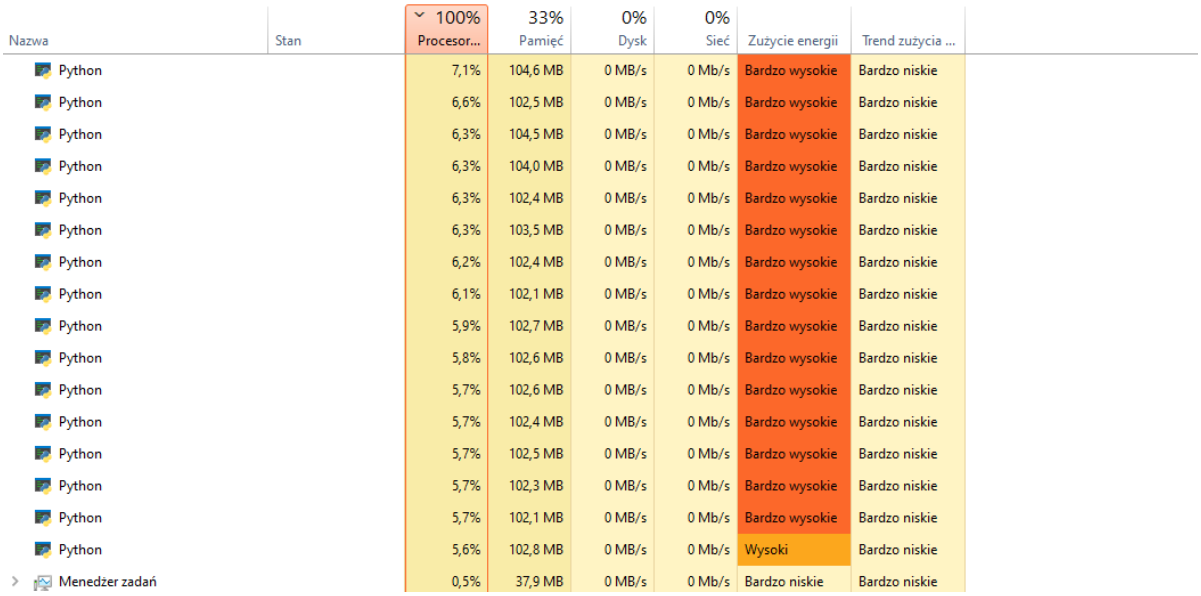

Nazwa	Stan	100% Procesor...	33% Pamięć	0% Dysk	0% Sieć	Zużycie energii	Trend zużycia ...
Python		7,1%	104,6 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		6,6%	102,5 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		6,3%	104,5 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		6,3%	104,0 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		6,3%	102,4 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		6,3%	103,5 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		6,2%	102,4 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		6,1%	102,1 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		5,9%	102,7 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		5,8%	102,6 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		5,7%	102,6 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		5,7%	102,4 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		5,7%	102,5 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		5,7%	102,3 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		5,7%	102,1 MB	0 MB/s	0 Mb/s	Bardzo wysokie	Bardzo niskie
Python		5,6%	102,8 MB	0 MB/s	0 Mb/s	Wysoki	Bardzo niskie
Menedżer zadań		0,5%	37,9 MB	0 MB/s	0 Mb/s	Bardzo niskie	Bardzo niskie

Część przedstawionych wykresów została wykonana na stacjonarnym komputerze z procesorem z 16 dostępnymi wątkami i wykonywanie ich z podanymi parametrami może skutkować bardzo długim czasem wykonania na jednostce obsługującej mniej wątków lub posiadającej znacząco słabsze rdzenie.

Opis algorytmu

Zadanie polegało na zaimplementowaniu perceptronu wielowarstwowego oraz wybranego algorytmu optymalizacji gradientowej z algorytmem propagacji wstecznej.

Perceptron wielowarstwowy został wytrenowany do klasyfikacji zbioru danych MNIST (http://yann.lecun.com/exdb/mnist/). Zbiór MNIST został załadowany poprzez (sklearn.datasets.load digits()).

Mateusz Daszewski i Miłosz Andryszczuk

Przygotowania

Domyślne parametry dla dalszych eksperymentów, zostały określone metodą prób i błędów i wynoszą:

liczba treningów na tym samym zbiorze danych - epochs: 100

wielkość skoku w algorytmie gradientu prostego - learning rate: 0,01

liczba przeanalizowanych przykładów przed wykonaniem propagacji wstecznej - batch_size: 8

liczba neuronów w kolejnych warstwach sieci - layers: 64, 128, 64, 10

Warstwy w dalszej części będą odnosić się do wartości między 64 i 10, takie liczby neuronów na początkowej i ostatniej warstwie są wymagane do poprawnego działania programu.

Wpływ learning rate na accuracy:

Pierwszy test:

Parametry: learning rate z zakresu 0.001 – 0.068 – 100 punktów na wykresie

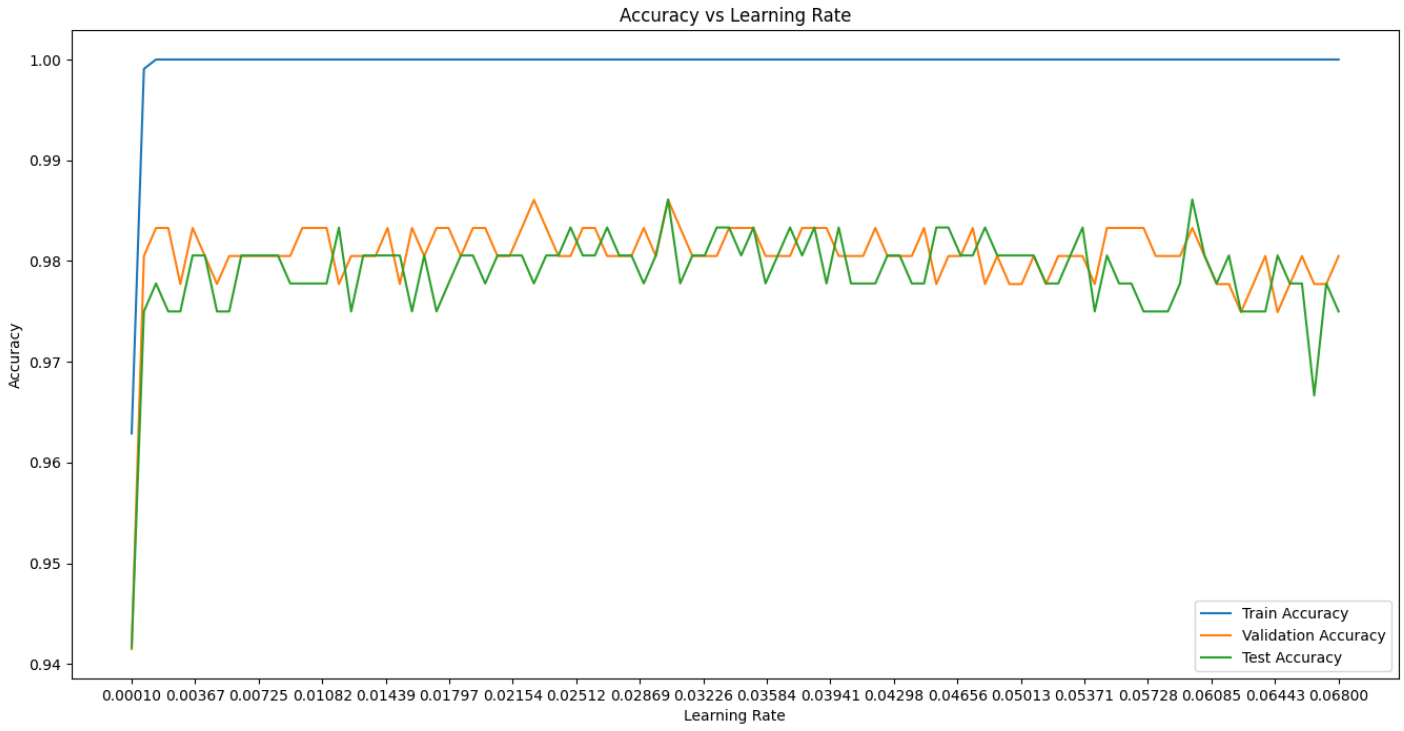

Obserwacje:

Bardzo małe wartości learning rate osiągają mniejsze wartości accuracy

Mateusz Daszewski i Miłosz Andryszczuk

Drugi test:

Te same parametry wykres jest medianą 5 wykonań

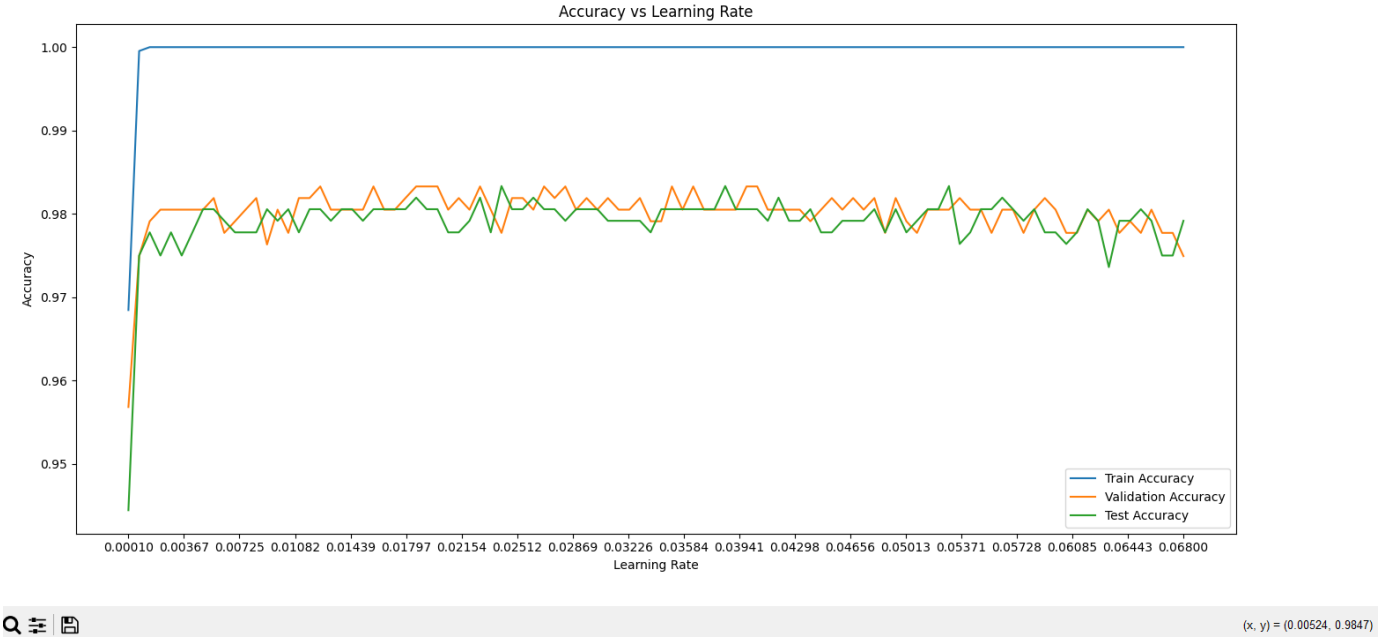

Trzeci test:

Początkowa wartość learning rate została ustawiona na 0,003, aby zapewnić dokładniejszy wykres

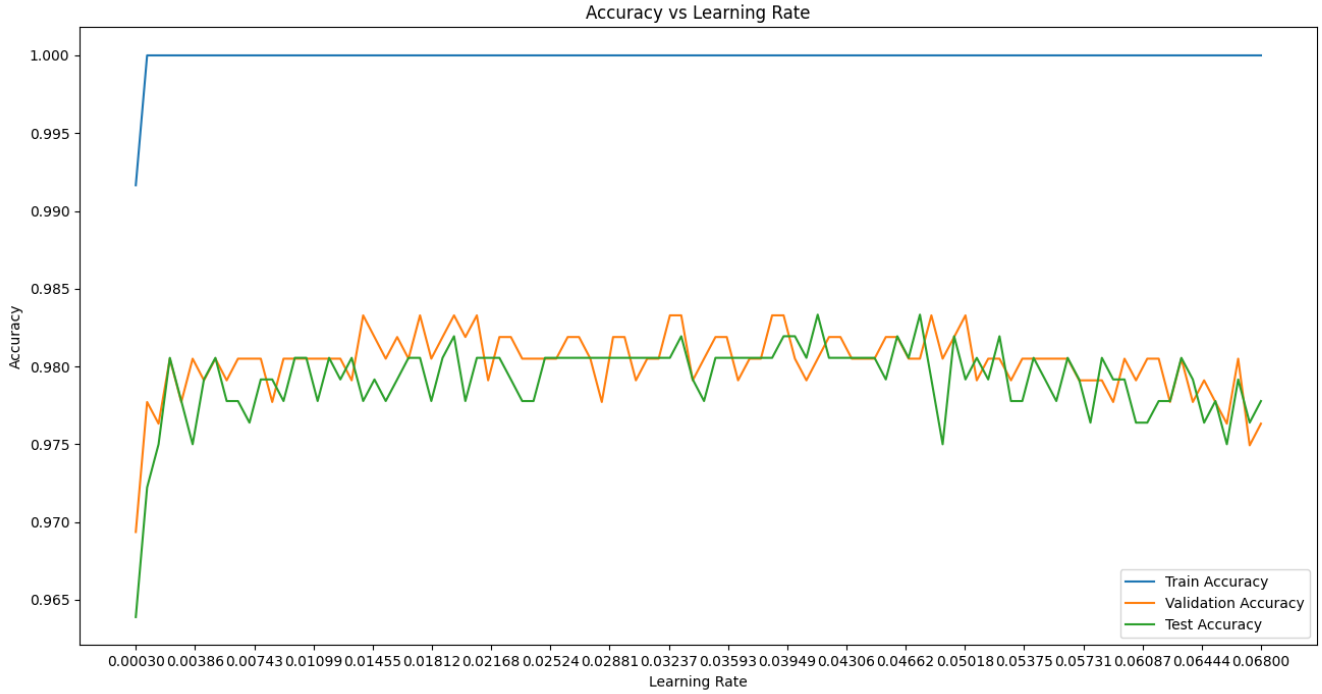

Obserwacje:

Zauważalny mały trend spadkowy zaczynający się około 0.05

Mateusz Daszewski i Miłosz Andryszczuk

Wpływ epochs na accuracy:

Ustawiony został zakres epochs między 1 i 80, badane jest 40 punktów, zakres dobrany dla optymalnej czytelności wykresu, wartości poniżej są medianą 10 wywołań

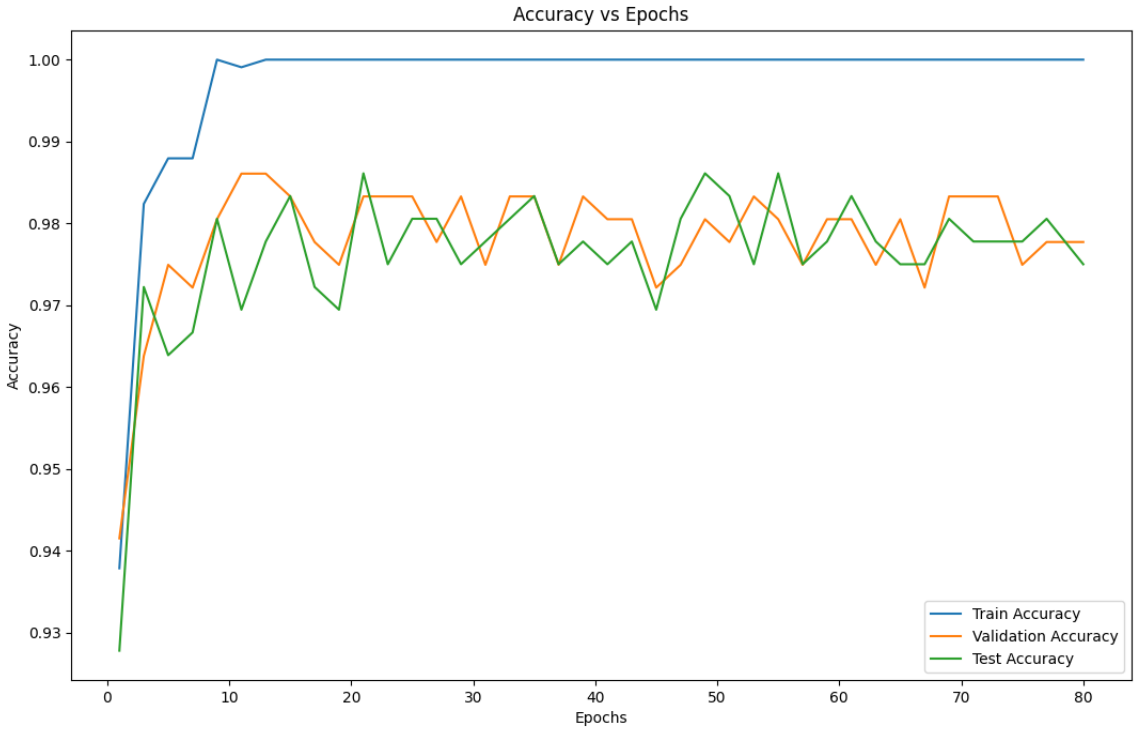

Obserwacje:

Małe wartości osiągają mniejsze wartości accuracy

Mateusz Daszewski i Miłosz Andryszczuk

Wpływ batch size na accuracy:

Ustawiony został zakres epochs między 1 i 64, badane jest 16 punktów, wartości poniżej są średnią 15 wywołań

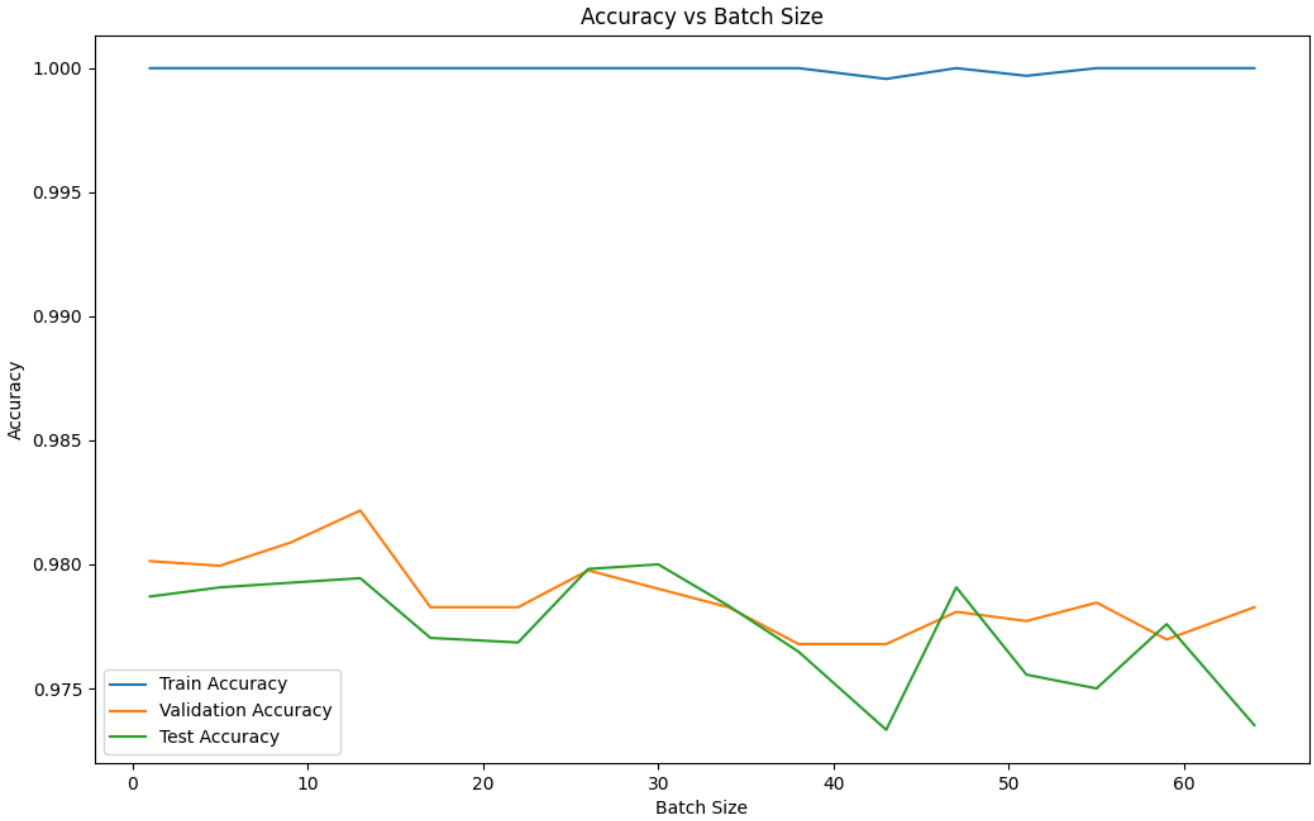

Obserwacje:

Wykonywanie treningu dla bardzo małych wartości zwiększa czas wykonania, natomiast generuje minimalnie lepsze wyniki

Wpływ ilości neuronów i ich ustawienie na accuracy :

Wszystkie testy dla warstw są medianą 5 wykonań

Pojedyncza warstwa:

Pierwszy test:

Warstwa o wielkości od 1 do 62

Mateusz Daszewski i Miłosz Andryszczuk

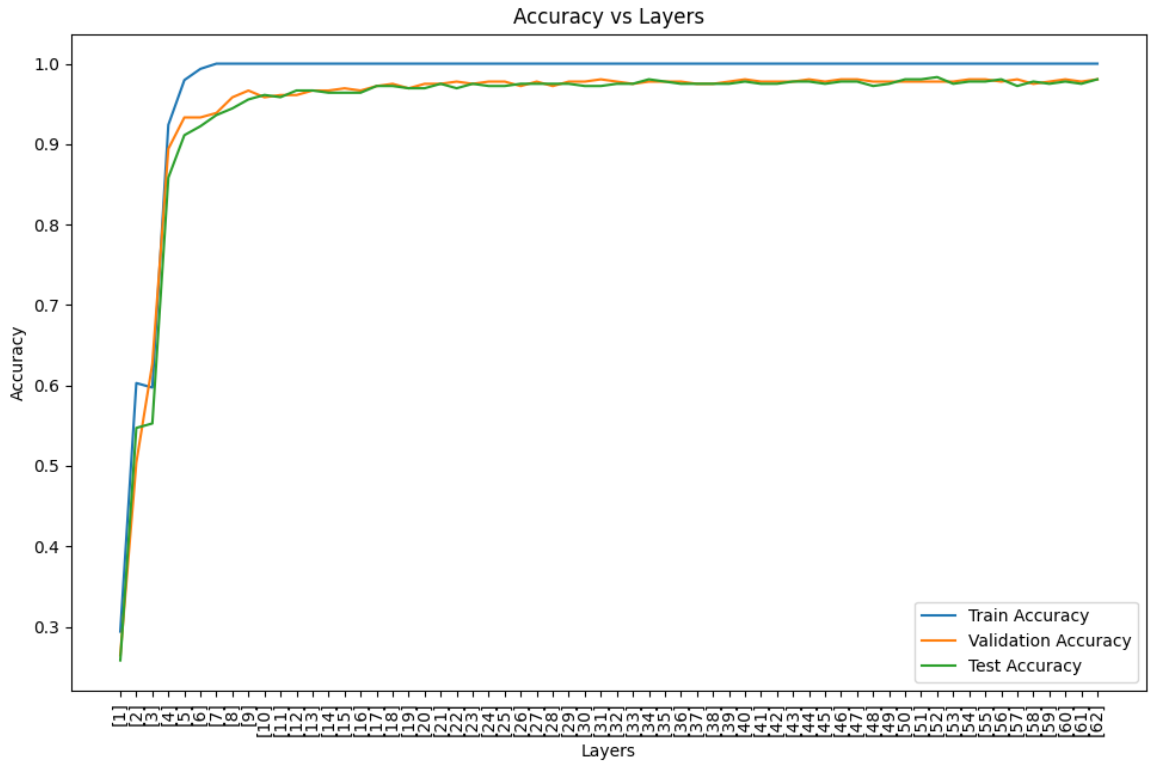

Obserwacje:

Bardzo mała liczba neuronów, uzyskuje bardzo małe wartości accuracy

Drugi test:

Wartości między 7 i 40

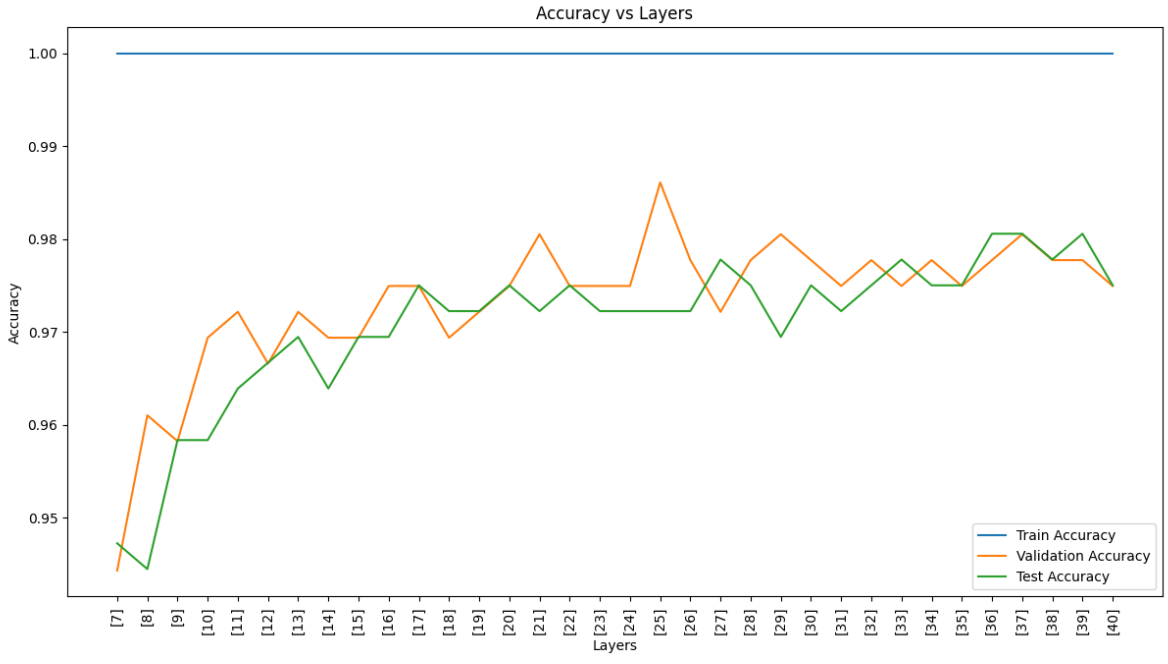

Obserwacje:

Wzrost accuarcy wraz z liczbą neuronów

Mateusz Daszewski i Miłosz Andryszczuk

Trzeci test:

Warstwa o wielkości od 25 do 124

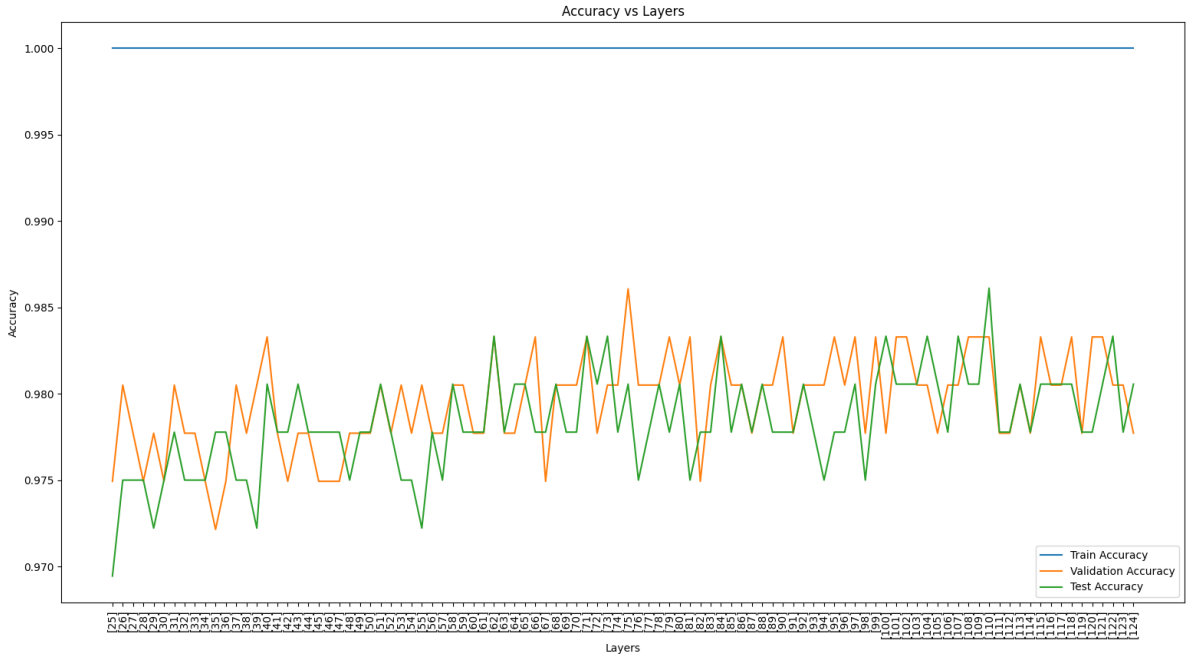

Obserwacje:
Mały wzrost dokładności wraz ze zwiększającą się liczbą neuronów

Podwójna warstwa:

Pierwszy test:

1/8 kombinacji 2 warstw o zakresach od 1 do 64

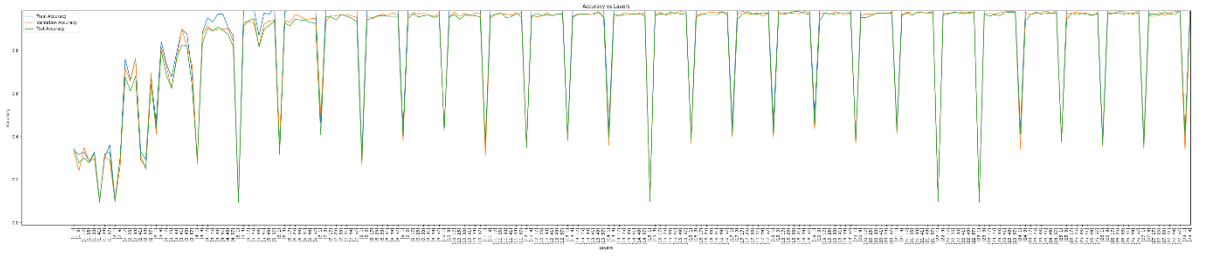

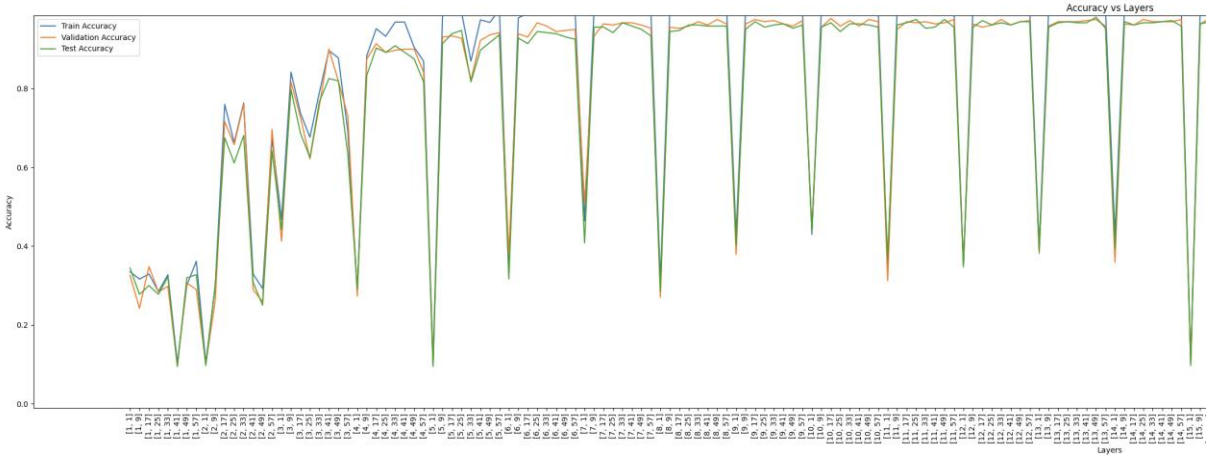

Mateusz Daszewski i Miłosz Andryszczuk
Obserwacje:

Pojedynczy neuron na warstwie, obniża znacząco accuracy. Mała liczba neuronów obniża accuracy.

Drugi test:

Wykres wszystkich kombinacji 2 warstw o wielkości z zakresu 1-16

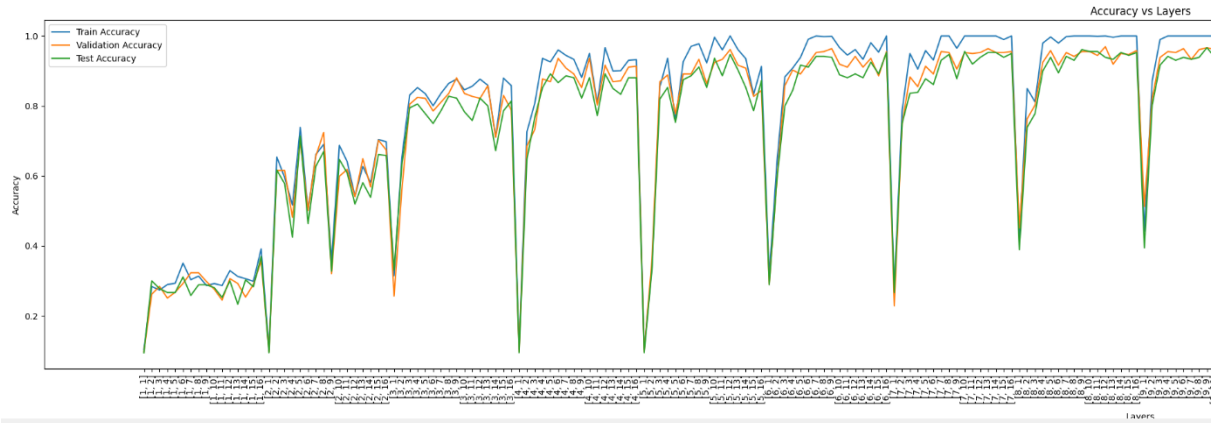

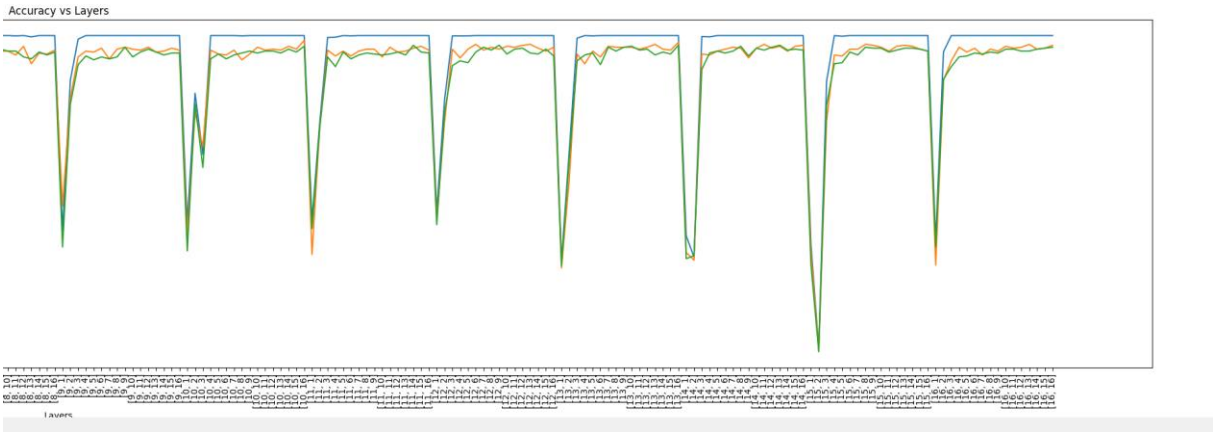

Obserwacje:

Bardzo mała dokładność w przypadku małej ilości neuronów w drugiej warstwie.

Przesortowany wykres względem a*b, a i b liczba neuronów na warstwach

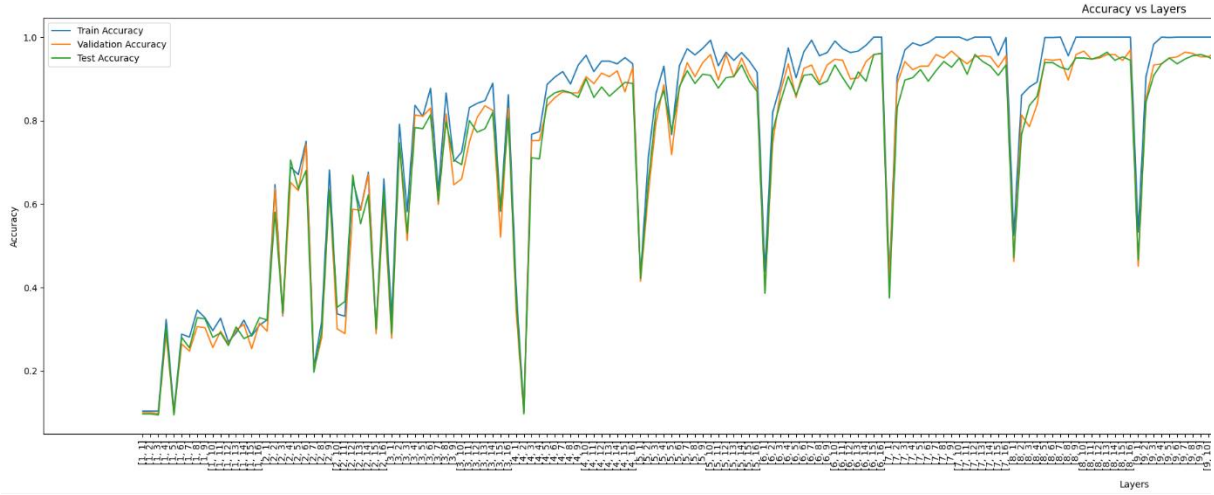

Obserwacje:

Małe wartości oraz warstwy z jednym neuronem utrudniają czytelność

Mateusz Daszewski i Miłosz Andryszczuk

Trzeci test:

Przesortowane wartości z poprzedniego testu, oraz ustawiono minimalną liczbę neuronów na warstwie na 4

Obserwacje:

Mała liczba neuronów na dowolnej warstwie obniża accuracy. Wraz z wzrostem liczby neuronów na obydwu warstwach wzrasta accuracy.

Czwarty test:

Wpływ batch size na poprzedni test, ustawiono wartość 2

Obserwacje:

Wykres jest bardziej „spłaszczony", co oznacza mniejsze spadki w dokładności. Czas obliczeniowy znacząco wzrósł, ponieważ propagacja wsteczna jest wykonywana znacznie częściej.

Czwarty test:

Wpływ batch size=1, na ten sam zakres nieposortowany, wartości z raz wykonanego testu

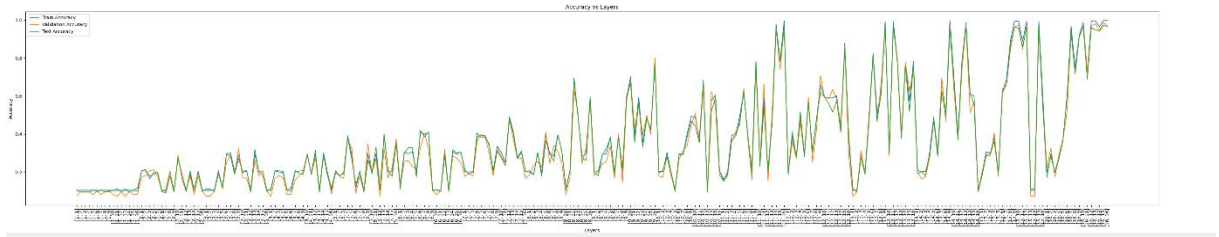

Mateusz Daszewski i Miłosz Andryszczuk

Obserwacje:

Wykres stał się bardziej „chaotyczny”. Nie był jednak generowany z wielu wykonań

Trzywarstwowe sieci:

Pierwszy test:

Wszystkie konfiguracje 3 warstwowych sieci z zakresem neuronów między 10-16

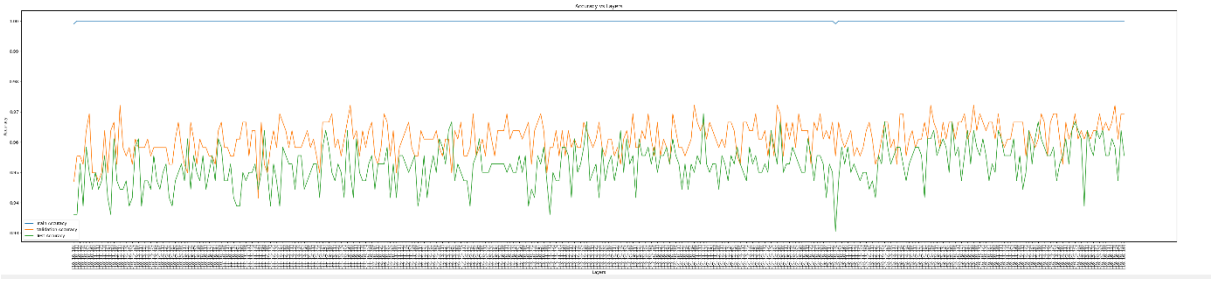

Obserwacje:

Mało czytelny wykres. Wszystkie wartości osiągają podobne wyniki

Drugi test:

Porównanie wybranych wartości layers, które mają równą wartość mnożenia liczy neuronów przez warstwy

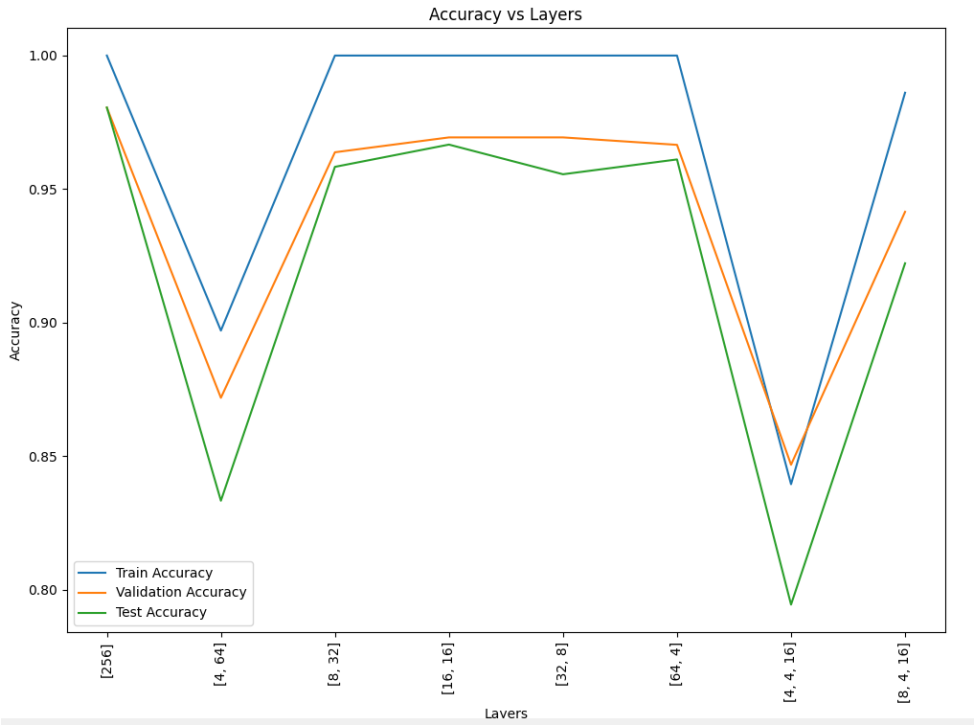

Mateusz Daszewski i Miłosz Andryszczuk

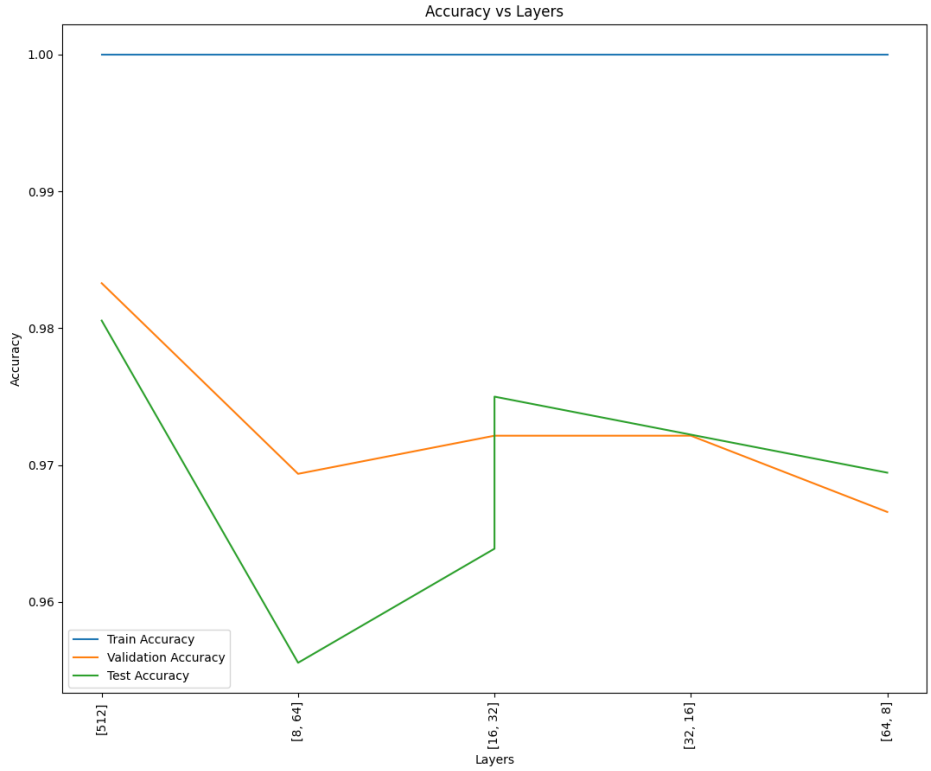

Obserwacje:

Warstwy z małą liczbą neuronów, obniżają accuracy

Trzeci test:

Porównanie wartości accuracy dla sieci z dużą liczbą neuronów

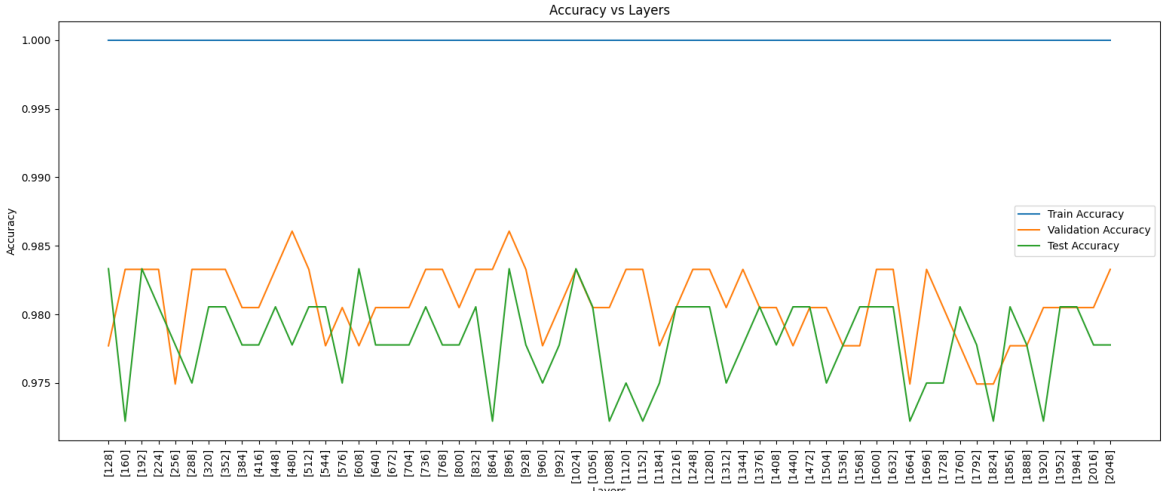

Mateusz Daszewski i Miłosz Andryszczuk

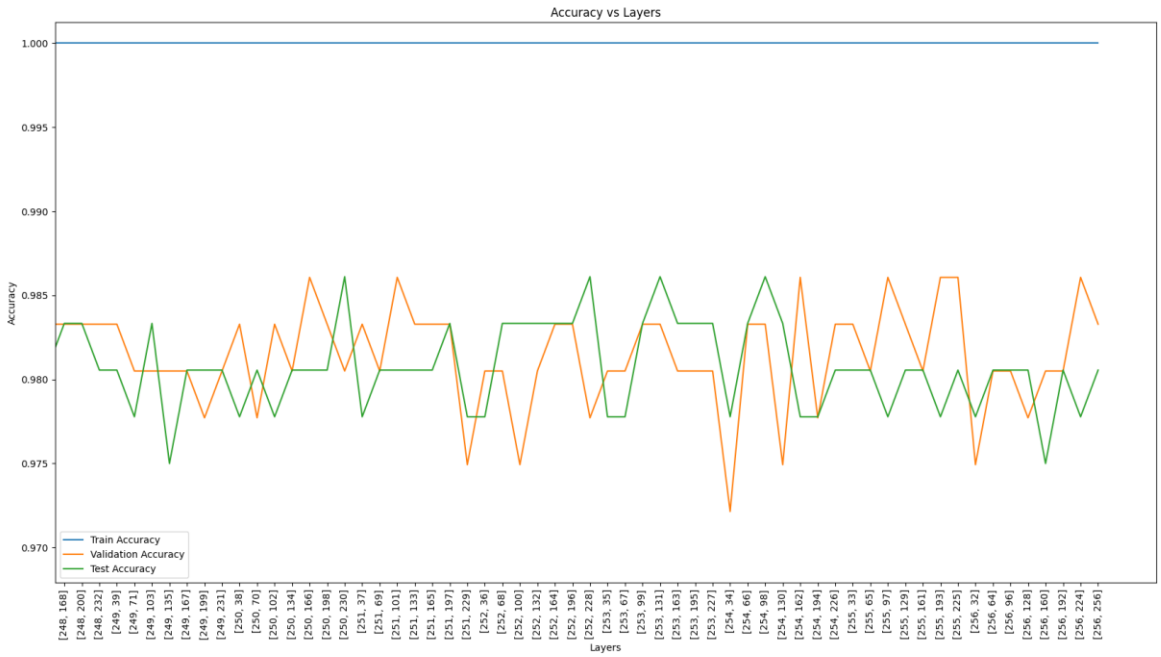

Wyniki i wnioski

Z analizy wpływu parametrów na accuracy wynika, że bardzo małe wartości learning rate, małe wartości epochs, oraz mała liczba neuronów mają negatywny wpływ na accuracy. Dodatkowo za duże wartości learning rate >0.07 powodują bardzo słabe wyniki accuracy.

Duże wartości dla batch size powodują mała utratę accuracy, natomiast bardzo małe wartości powodują dłuższe wykonywanie algorytmu jednak z minimalnym pozytywnym wpływem na accuracy, co dowodzi poprawności działania algorytmu optymalizującego.

Wartości epochs dla dobranych wartości negatywnie wpływają tylko dla małych wartości, po osiągnięciu wartości koło 20 wykres zaczyna się wypłaszczać.

Największy wpływ oraz ciekawe wartości generuje dobieranie wartości layers. Dla sieci z jedną wewnętrzną warstwą im więcej neuronów tym wyższa dokładność, która wypłaszcza się po osiągnięciu 70 neuronów.

Dla sieci dwuwarstwowej można zauważyć negatywny wpływ warstw o małej liczbie neuronów w szczególności dla jednego neurona. Można zauważyć, że taka warstwa pomimo dużej liczby neuronów na poprzedniej warstwie, bardzo negatywnie wpływa na dokładność. Również inne wartości mniejsze niż 8 negatywnie wpływają na dokładność, jednak na nią częściowo negatywnie wpływa również za duża wartość batch size jak ukazuje wykres w czwartym teście dla sieci dwuwarstwowych.

Sieci powyżej dwóch warstw nie poprawiają znacząco accuracy, jednak znacząco zwiększają czas wykonywania się programu. Negatywny wpływ na dokładność mają również warstwy o za małej liczbie neuronów, szczególnie mniejsze niż 8.